

Analyse de données démographiques

Projet informatique – Bureau d'études

EILCO – CP1 – Semestre 2 – 2024-2025

Encadrants : Arnaud Liefoghe, Denis Robilliard, Benoît Fortin

Description

Dans le cadre de ce projet, vous développerez une application en Python permettant d'analyser et de visualiser les données démographiques françaises issues de l'INSEE. Les données sont disponibles en licence ouverte à cette adresse :

<https://www.data.gouv.fr/en/datasets/estimations-de-population/>

Les données présentent la répartition annuelle de la population au 1er janvier par sexe et par groupe d'âges, pour différentes échelles géographiques. La période couverte s'étend du 1er janvier 1990 au 1er janvier 2024.

Les objectifs pédagogiques du projet sont les suivants :

- Mettre en pratique la programmation orientée objet,
- Développer des compétences en manipulation de données,
- Développer des compétences en visualisation de données,
- Produire un reporting de données pertinent pour synthétiser l'information.

Modalités

Le travail se fera obligatoirement en binôme (sauf exception justifiée et validée par vos encadrants).

L'évaluation du projet reposera sur trois éléments de même coefficient : le **code source**, un **rapport technique** de présentation du travail et un **contrôle écrit** individuel. La note finale sera la moyenne de ces trois notes.

Le code source et le rapport doivent être déposés sur le cloud EILCO dans votre répertoire « stages/projets » (accessible aux enseignants) au plus tard le **vendredi 23 mai**. Une pénalité de 1 point sera appliquée par tranche de 8 heures de retard (soit 3 points par jour) après la date de dépôt. Les fichiers doivent être déposés dans une archive ZIP nommée impérativement « nom1_nom2_BE.zip ». Les noms et prénoms des membres du binôme doivent figurer à la fois dans le rapport et en commentaire en tête du programme. Attention : l'absence de vos noms entraînera automatiquement une note de 0 sur le rapport et/ou le programme ; vérifiez soigneusement !

Le **rapport** (3 à 5 pages, hors page de garde, en-tête et sommaire) doit présenter les éléments qui ont été réalisés et non par rapport aux attendus du sujet, les difficultés rencontrées et les choix techniques effectués, en particulier concernant la structure du code et l'organisation des classes et méthodes. Il doit aussi contenir un bref guide d'utilisation. La qualité de la rédaction sera prise en compte dans l'évaluation.

Il est essentiel de respecter les règles de bonne pratique en développement logiciel (leur non-respect entraînera des pénalités). Vous devez, en particulier, utiliser autant que possible les **concepts de programmation orientée objet** (classes, méthodes, etc.) enseignés au second semestre. Ce point sera un critère majeur dans l'évaluation de votre code. Parmi les règles de qualité du code, une attention particulière sera portée aux éléments suivants :

- L'utilisation d'une **nomenclature** claire et pertinente pour les variables, méthodes et classes, permettant une compréhension intuitive du code sans recours excessif aux commentaires (principe du

code auto-documenté).

- La **structuration** en méthodes concises et cohérentes, chacune ayant une fonctionnalité unique et bien définie.
- Le respect rigoureux des **conventions** de mise en forme du code, notamment concernant l'utilisation des espaces, selon les normes étudiées au 1er semestre (et détaillées ici : <https://peps.python.org/pep-0008/>).

Le contrôle écrit se déroulera lors de la dernière séance. Il évaluera votre compréhension du projet et de sa réalisation. Vous devrez maîtriser l'ensemble du code et des algorithmes, et être en mesure d'apporter des modifications au code existant. Cette évaluation est individuelle, même si le projet a été réalisé en binôme.

Cahier des charges

1. Étude et description des données brutes

Avant de commencer le développement, il est essentiel d'analyser attentivement la structure et le contenu des fichiers de données fournis. Vous devrez étudier l'organisation des colonnes (les attributs), identifier les différents types de données présents, comprendre la signification de chaque champ et repérer d'éventuelles particularités ou anomalies dans les données. Cette phase d'analyse préliminaire vous permettra de mieux concevoir vos structures de données et vos algorithmes de traitement.

2. Importation du fichier CSV de l'INSEE

L'importation du fichier de données peut s'effectuer ainsi :

```
with open('DS_ESTIMATION_POPULATION_CSV_FR/data.csv', 'r') as entree:
    lignes = entree.readlines()
```

La liste `lignes` contient alors des chaînes de caractères, chacune représentant une ligne complète du fichier d'entrée. La taille de la liste est `272974`. Examinez attentivement le contenu de cette liste.

3. Nettoyage et vérification des données

La première étape consiste à nettoyer les données. Pour cela, vous devez parcourir la liste `lignes` et, pour chaque chaîne de caractères, la découper (avec la méthode `split`) selon les attributs, puis transformer les éventuelles valeurs numériques en entiers (`int`).

Attention : seules les données démographiques par département vont nous intéresser, c'est-à-dire les lignes dont `GEO_OBJECT` vaut `DEP` et dont `EP_MEASURE` vaut `POP`. Les autres lignes doivent donc être ignorées. De même, nous nous concentrerons uniquement sur cinq attributs : le département, l'année, l'âge, le sexe et la taille de la population. Les autres attributs peuvent être ignorés. Dans le fichier d'entrée, l'âge est organisé par tranches d'âge. Pour simplifier, nous utiliserons l'âge minimal de chaque tranche : `0` pour `Y_LT5`, `5` pour `Y5T9`, `10` pour `Y10T14`, ..., `95` pour `Y_GE95`.

Après le nettoyage des données, vous devriez obtenir `173556` entrées.

4. Organisation du code

Le code doit être structuré en classes appropriées, comprenant au minimum les classes suivantes :

- Classe `Conversion`
 - Attributs : Aucun.
 - Méthodes : fonctions nécessaires pour réaliser les transformations de nettoyage de données décrites ci-dessus (Section 3).

- Classe `DonneeDemographique` pour manipuler une entrée
 - Attributs : au moins `departement`, `annee`, `age`, `sexe`, `population`.
 - Méthodes : au moins `__init__`, `__str__`, `__lt__` (comparaison par département, puis par âge, puis par sexe).
- Classe `CollectionDemographique` pour manipuler l'ensemble des entrées
 - Attributs : au moins `liste`.
 - Méthodes: au minimum `__init__`, `__str__`, `__len__`, `sort` (utilisant le comparateur défini précédemment), ainsi que :
 - Méthode `ajouter` permettant d'ajouter une entrée à la collection,
 - Méthode `departement` qui retourne la liste des départements de la collection (telle qu'elle apparaît dans la collection, sans changer l'ordre),
 - Méthode `annee` : idem pour les années,
 - Méthode `age` : idem pour les âges,
 - Méthode `sexe` : idem pour les sexes,
 - Méthode `population` : idem pour les tailles de population,
 - Méthode `filtre_departement` qui retourne les données d'un département particulier (sans changer l'ordre),
 - Méthode `filtre_annee` : idem pour une année,
 - Méthode `filtre_age` : idem pour un âge,
 - Méthode `filtre_sexe` : idem pour un sexe,
 - Méthode `filtre_age_diff` qui retourne les données qui ne correspondent pas à un âge particulier (sans changer l'ordre),
 - Méthode `filtre_sexe_diff` : idem pour un sexe.

On peut remarquer que la plupart de ces fonctions sélectionnent un sous-ensemble de lignes ou de colonnes sur les données.

- Classe `Reporting`
 - Attributs : Aucun.
 - Méthodes : méthodes nécessaires pour réaliser les fonctionnalités décrites ci-dessous (Section 5).

Chaque classe doit être implémentée dans un fichier distinct. Un fichier principal (`Main`) sera développé pour exécuter les différentes étapes du projet.

5. Fonctionnalités d'analyse statistique et de visualisation

Pour la visualisation des données, nous utiliserons exclusivement `matplotlib`, une bibliothèque de visualisation pour Python. Voici un exemple simple pour créer un graphique :

```
import matplotlib.pyplot as plt

# Création de données artificielles
x = [1, 2, 3, 4, 5, 6, 7, 8, 9]
y1 = [1, 4, 2, 3, 1, 4, 2, 3, 1]
y2 = [2, 3, 3, 1, 2, 3, 3, 1, 2]
```

```
# Création du graphique
plt.scatter(x, y1, color='red', label='label 1')
plt.scatter(x, y2, color='blue', label='label 2')

# Affichage de la légende
plt.legend()

# Affichage du graphique
plt.show()
```

Ce code génère un graphique de points dont les positions sont définies par les coordonnées `x` et `y`. Cet exemple est simple. La bibliothèque offre de nombreuses possibilités pour créer des visualisations plus élaborées et personnalisées.

Voici les fonctionnalités d'analyse et de visualisation à développer :

1. Visualisation de l'évolution démographique

- Créer un graphique montrant l'évolution de la population totale (tous âges et sexes confondus) du département 62 (Pas-de-Calais) de 1990 à 2024.
- Utiliser les filtres définis ci-dessus pour préparer les données.
- Utiliser `matplotlib` avec des axes correctement libellés.

2. Comparaison entre départements

- Sur un même graphique, tracer l'évolution de la population pour les départements 62 (Pas-de-Calais), 59 (Nord, département le plus peuplé) et 48 (Lozère, département le moins peuplé).
- Utiliser différentes couleurs et une légende pour distinguer les départements.

3. Analyse par genre

- Créer un graphique comparant l'évolution de la population masculine et féminine du département 62 (Pas-de-Calais).
- Utiliser deux couleurs distinctes avec une légende appropriée.

4. Analyse par département

- Créer un graphique représentant la population de chaque département pour l'année 2024.
- Ajouter une échelle de couleur pour représenter les différentes tranches de population.

5. Analyse de l'âge moyen par département

- Calculer et visualiser l'âge moyen de la population pour chaque département pour l'année 2024.
- Créer un graphique comparatif entre les départements.

6. Analyse des taux de natalité et mortalité

- Calculer les taux de natalité et mortalité du département 62 (Pas-de-Calais) depuis 1991.
- Créer un graphique montrant l'évolution de ces taux sur la période étudiée.

7. Projection démographique

- En utilisant les taux de natalité et mortalité que vous avez calculés pour 2024, créer un graphique montrant la projection de la population du département 62 (Pas-de-Calais) jusqu'en 2050.